

矩阵求导术（上）



长驱鬼侠
数学爱好者

2,166 人赞同了该文章

矩阵求导的技术，在统计学、控制论、机器学习等领域有广泛的应用。鉴于我看过的一些资料或言之不详、或繁乱无绪，本文来做科普，分作两篇，上篇讲标量对矩阵的求导术，下篇讲矩阵对矩阵的求导术。本文使用小写字母 x 表示标量，粗体小写字母 \mathbf{x} 表示（列）向量，大写字母 X 表示矩阵。

首先来琢磨一下定义，标量 f 对矩阵 X 的导数，定义为 $\frac{\partial f}{\partial X} = \left[\frac{\partial f}{\partial x_{ij}} \right]$ ，即 f 对 X 逐元素求导排成与 X 尺寸相同的矩阵。然而，这个定义在计算中并不好用，实用上的原因是对函数较复杂的情形难以逐元素求导；哲学上的原因是逐元素求导破坏了**整体性**。试想，为何要将 f 看做矩阵 X 而不是各元素 X_{ij} 的函数呢？答案是用矩阵运算更整洁。所以在求导时不宜拆开矩阵，而是要找一个从整体出发的算法。

为此，我们来回顾，一元微积分中的导数（标量对标量的导数）与微分有联系： $df = f'(x)dx$ ；多元微积分中的梯度（标量对向量的导数）也与微分有联系： $df = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i = \frac{\partial f}{\partial \mathbf{x}}^T d\mathbf{x}$ ，这里第一个等号是全微分公式，第二个等号表达了梯度与微分的联系：全微分 df 是梯度向量 $\frac{\partial f}{\partial \mathbf{x}}$ （ $n \times 1$ ）与微分向量 $d\mathbf{x}$ （ $n \times 1$ ）的内积；受此启发，我们将矩阵导数与微分建立联系：

$df = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial f}{\partial x_{ij}} dx_{ij} = \text{tr} \left(\frac{\partial f}{\partial X}^T dX \right)$ 。其中 tr 代表迹(trace)是方阵对角线元素之和，满足性质：对尺寸相同的矩阵 A, B ， $\text{tr}(A^T B) = \sum_{i,j} A_{ij} B_{ij}$ ，即 $\text{tr}(A^T B)$ 是矩阵 A, B 的**内积**。与梯度相似，这里第一个等号是全微分公式，第二个等号表达了矩阵导数与微分的联系：全微分 df 是导数 $\frac{\partial f}{\partial X}$ （ $m \times n$ ）与微分矩阵 dX （ $m \times n$ ）的内积。

然后来建立运算法则。回想遇到较复杂的一元函数如 $f = \log(2 + \sin x)e^{\sqrt{x}}$ ，我们是如何求导的呢？通常不是从定义开始求极限，而是先建立了初等函数求导和四则运算、复合等法则，再来运用这些法则。故而，我们来创立常用的矩阵微分的运算法则：

- 加减法： $d(X \pm Y) = dX \pm dY$ ；矩阵乘法： $d(XY) = (dX)Y + XdY$ ；转置： $d(X^T) = (dX)^T$ ；迹： $d\text{tr}(X) = \text{tr}(dX)$ 。
- 逆： $dX^{-1} = -X^{-1}dXX^{-1}$ 。此式可在 $XX^{-1} = I$ 两侧求微分来证明。
- 行列式： $d|X| = \text{tr}(X^\# dX)$ ，其中 $X^\#$ 表示 X 的伴随矩阵，在 X 可逆时又可以写作 $d|X| = |X|\text{tr}(X^{-1}dX)$ 。此式可用Laplace展开来证明，详见张贤达《矩阵分析与应用》第279页。
- 逐元素乘法： $d(X \odot Y) = dX \odot Y + X \odot dY$ ， \odot 表示尺寸相同的矩阵 X, Y 逐元素相乘。
- 逐元素函数： $d\sigma(X) = \sigma'(X) \odot dX$ ， $\sigma(X) = [\sigma(X_{ij})]$ 是逐元素标量函数运算， $\sigma'(X) = [\sigma'(X_{ij})]$ 是逐元素求导数。举个例子， $X = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix}$ ， $d\sin(X) = \begin{bmatrix} \cos x_{11} dx_{11} & \cos x_{12} dx_{12} \\ \cos x_{21} dx_{21} & \cos x_{22} dx_{22} \end{bmatrix} = \cos(X) \odot dX$ 。

我们试图利用矩阵导数与微分的联系 $df = \text{tr} \left(\frac{\partial f}{\partial X}^T dX \right)$ ，在求出左侧的微分 df 后，该如何写成右侧的形式并得到导数呢？这需要一些迹技巧(trace trick)：

- 标量套上迹： $a = \text{tr}(a)$
- 转置： $\text{tr}(A^T) = \text{tr}(A)$ 。
- 线性： $\text{tr}(A \pm B) = \text{tr}(A) \pm \text{tr}(B)$ 。

▲ 赞同 2.2K ▼

● 248 条评论

➤ 分享

★ 收藏

...



4. 矩阵乘法交换： $\text{tr}(AB) = \text{tr}(BA)$ ，其中 A 与 B^T 尺寸相同。两侧都等于 $\sum_{i,j} A_{ij} B_{ji}$ 。

5. 矩阵乘法/逐元素乘法交换： $\text{tr}(A^T(B \odot C)) = \text{tr}((A \odot B)^T C)$ ，其中 A, B, C 尺寸相同。两侧都等于 $\sum_{i,j} A_{ij} B_{ij} C_{ij}$ 。

观察一下可以断言，若标量函数 f 是矩阵 X 经加减乘法、逆、行列式、逐元素函数等运算构成，则使用相应的运算法则对 f 求微分，再使用迹技巧给 df 套上迹并将其它项交换至 dX 左侧，对照导数与微分的联系 $df = \text{tr} \left(\frac{\partial f^T}{\partial X} dX \right)$ ，即能得到导数。

特别地，若矩阵退化为向量，对照导数与微分的联系 $df = \frac{\partial f^T}{\partial \mathbf{x}} d\mathbf{x}$ ，即能得到导数。

在建立法则的最后，来谈一谈复合：假设已求得 $\frac{\partial f}{\partial Y}$ ，而 Y 是 X 的函数，如何求 $\frac{\partial f}{\partial X}$ 呢？在微积分中有标量求导的链式法则 $\frac{\partial f}{\partial x} = \frac{\partial f}{\partial y} \frac{\partial y}{\partial x}$ ，但这里我们不能随意沿用标量的链式法则，因为矩阵对矩阵的导数 $\frac{\partial Y}{\partial X}$ 截至目前仍是未定义的。于是我们继续追本溯源，链式法则是从何而来？源头仍然是微分。我们直接从微分入手建立复合法则：先写出 $df = \text{tr} \left(\frac{\partial f^T}{\partial Y} dY \right)$ ，再将 dY 用 dX 表示出来代入，并使用迹技巧将其他项交换至 dX 左侧，即可得到 $\frac{\partial f}{\partial X}$ 。

最常见的情形是 $Y = AXB$ ，此时

$df = \text{tr} \left(\frac{\partial f^T}{\partial Y} dY \right) = \text{tr} \left(\frac{\partial f^T}{\partial Y} A dX B \right) = \text{tr} \left(B \frac{\partial f^T}{\partial Y} A dX \right) = \text{tr} \left((A^T \frac{\partial f}{\partial Y} B^T)^T dX \right)$ ，可得到 $\frac{\partial f}{\partial X} = A^T \frac{\partial f}{\partial Y} B^T$ 。注意这里 $dY = (dA)XB + AdXB + AXdB = AdXB$ ，由于 A, B 是常量， $dA = 0, dB = 0$ ，以及我们使用矩阵乘法交换的迹技巧交换了 $\frac{\partial f^T}{\partial Y} A dX$ 与 B 。

接下来演示一些算例。特别提醒要依据已经建立的运算法则来计算，不能随意套用微积分中标量导数的结论，比如认为 AX 对 X 的导数为 A ，这是没有根据、意义不明的。

例1： $f = \mathbf{a}^T X \mathbf{b}$ ，求 $\frac{\partial f}{\partial X}$ 。其中 \mathbf{a} 是 $m \times 1$ 列向量， X 是 $m \times n$ 矩阵， \mathbf{b} 是 $n \times 1$ 列向量， f 是标量。

解：先使用矩阵乘法法则求微分， $df = d\mathbf{a}^T X \mathbf{b} + \mathbf{a}^T dX \mathbf{b} + \mathbf{a}^T X d\mathbf{b} = \mathbf{a}^T dX \mathbf{b}$ ，注意这里的 \mathbf{a}, \mathbf{b} 是常量， $d\mathbf{a} = 0, d\mathbf{b} = 0$ 。由于 df 是标量，它的迹等于自身， $df = \text{tr}(df)$ ，套上迹并做矩阵乘法交换： $df = \text{tr}(\mathbf{a}^T dX \mathbf{b}) = \text{tr}(\mathbf{b} \mathbf{a}^T dX) = \text{tr}((\mathbf{b} \mathbf{a}^T)^T dX)$ ，注意这里我们根据 $\text{tr}(AB) = \text{tr}(BA)$ 交换了 $\mathbf{a}^T dX$ 与 \mathbf{b} 。对照导数与微分的联系 $df = \text{tr} \left(\frac{\partial f^T}{\partial X} dX \right)$ ，得到 $\frac{\partial f}{\partial X} = \mathbf{b} \mathbf{a}^T$ 。

注意：这里不能用 $\frac{\partial f}{\partial X} = \mathbf{a}^T \frac{\partial X}{\partial X} \mathbf{b} = ?$ ，导数与矩阵乘法的交换是不合法则的运算（而微分是合法的）。有些资料在计算矩阵导数时，会略过求微分这一步，这是逻辑上解释不通的。

例2： $f = \mathbf{a}^T \exp(X\mathbf{b})$ ，求 $\frac{\partial f}{\partial X}$ 。其中 \mathbf{a} 是 $m \times 1$ 列向量， X 是 $m \times n$ 矩阵， \mathbf{b} 是 $n \times 1$ 列向量， \exp 表示逐元素求指数， f 是标量。

解：先使用矩阵乘法、逐元素函数法则求微分： $df = \mathbf{a}^T (\exp(X\mathbf{b}) \odot (dX\mathbf{b}))$ ，再套上迹并做交换： $df = \text{tr}(\mathbf{a}^T (\exp(X\mathbf{b}) \odot (dX\mathbf{b}))) = \text{tr}((\mathbf{a} \odot \exp(X\mathbf{b}))^T dX \mathbf{b})$
 $= \text{tr}(\mathbf{b} (\mathbf{a} \odot \exp(X\mathbf{b}))^T dX) = \text{tr}(((\mathbf{a} \odot \exp(X\mathbf{b})) \mathbf{b}^T)^T dX)$ ，注意这里我们先根据 $\text{tr}(A^T(B \odot C)) = \text{tr}((A \odot B)^T C)$ 交换了 $\mathbf{a} \odot \exp(X\mathbf{b})$ 与 $dX \mathbf{b}$ ，再根据 $\text{tr}(AB) = \text{tr}(BA)$ 交换了 $(\mathbf{a} \odot \exp(X\mathbf{b}))^T dX$ 与 \mathbf{b} 。对照导数与微分的联系 $df = \text{tr} \left(\frac{\partial f^T}{\partial X} dX \right)$ ，得到 $\frac{\partial f}{\partial X} = (\mathbf{a} \odot \exp(X\mathbf{b})) \mathbf{b}^T$ 。

例3： $f = \text{tr}(Y^T M Y)$, $Y = \sigma(WX)$ ，求 $\frac{\partial f}{\partial X}$ 。其中 W 是 $l \times m$ 列向量， X 是 $m \times n$ 矩阵， Y 是 $l \times n$ 矩阵， M 是 $l \times l$ 对称矩阵， σ 是逐元素函数， f 是标量。

解：先求 $\frac{\partial f}{\partial Y}$ ，求微分，使用矩阵乘法、转置法则：

$df = \text{tr}((dY)^T M Y) + \text{tr}(Y^T M dY) = \text{tr}(Y^T M^T dY) + \text{tr}(Y^T M dY) = \text{tr}(Y^T (M + M^T) dY)$ ，对照导数与微分的联系，得到 $\frac{\partial f}{\partial Y} = (M + M^T)Y = 2MY$ ，注意这里 M 是对称矩阵。为求 $\frac{\partial f}{\partial X}$ ，写出

$df = \text{tr}\left(\frac{\partial f}{\partial Y} dY\right)$ ，再将 dY 用 dX 表示出来代入，并使用矩阵乘法/逐元素乘法交换：

$df = \text{tr}\left(\frac{\partial f}{\partial Y} (\sigma'(WX) \odot (W dX))\right) = \text{tr}\left(\left(\frac{\partial f}{\partial Y} \odot \sigma'(WX)\right)^T W dX\right)$ ，对照导数与微分的联系，得到 $\frac{\partial f}{\partial X} = W^T \left(\frac{\partial f}{\partial Y} \odot \sigma'(WX)\right) = W^T ((2M\sigma(WX)) \odot \sigma'(WX))$ 。

例4【线性回归】： $l = \|Xw - y\|^2$ ，求 w 的最小二乘估计，即求 $\frac{\partial l}{\partial w}$ 的零点。其中 y 是 $m \times 1$ 列向量， X 是 $m \times n$ 矩阵， w 是 $n \times 1$ 列向量， l 是标量。

解：这是标量对向量的导数，不过可以把向量看做矩阵的特例。先将向量模平方改写成向量与自身的内积： $l = (Xw - y)^T (Xw - y)$ ，求微分，使用矩阵乘法、转置等法则：

$dl = (Xdw)^T (Xw - y) + (Xw - y)^T (Xdw) = 2(Xw - y)^T X dw$ 。对照导数与微分的联系 $dl = \frac{\partial l}{\partial w} dw$ ，得到 $\frac{\partial l}{\partial w} = 2X^T (Xw - y)$ 。 $\frac{\partial l}{\partial w} = 0$ 即 $X^T Xw = X^T y$ ，得到 w 的最小二乘估计为 $w = (X^T X)^{-1} X^T y$ 。

例5【方差的最大似然估计】：样本 $x_1, \dots, x_N \sim \mathcal{N}(\mu, \Sigma)$ ，求方差 Σ 的最大似然估计。写成数学式是： $l = \log |\Sigma| + \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^T \Sigma^{-1} (x_i - \bar{x})$ ，求 $\frac{\partial l}{\partial \Sigma}$ 的零点。其中 x_i 是 $m \times 1$ 列向量，

$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ 是样本均值， Σ 是 $m \times m$ 对称正定矩阵， l 是标量， \log 表示自然对数。

解：首先求微分，使用矩阵乘法、行列式、逆等运算法则，第一项是

$d \log |\Sigma| = |\Sigma|^{-1} d|\Sigma| = \text{tr}(\Sigma^{-1} d\Sigma)$ ，第二项是

$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^T d\Sigma^{-1} (x_i - \bar{x}) = -\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^T \Sigma^{-1} d\Sigma \Sigma^{-1} (x_i - \bar{x})$ 。再给第二项套上述做交

换： $\text{tr}\left(\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^T \Sigma^{-1} d\Sigma \Sigma^{-1} (x_i - \bar{x})\right) = \frac{1}{N} \sum_{i=1}^N \text{tr}((x_i - \bar{x})^T \Sigma^{-1} d\Sigma \Sigma^{-1} (x_i - \bar{x}))$

$= \frac{1}{N} \sum_{i=1}^N \text{tr}(\Sigma^{-1} (x_i - \bar{x})(x_i - \bar{x})^T \Sigma^{-1} d\Sigma) = \text{tr}(\Sigma^{-1} S \Sigma^{-1} d\Sigma)$ ，其中先交换迹与求和，然后将

$\Sigma^{-1} (x_i - \bar{x})(x_i - \bar{x})^T \Sigma^{-1}$ 交换到左边，最后再交换迹与求和，并定义 $S = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(x_i - \bar{x})^T$ 为样本方

差矩阵。得到 $dl = \text{tr}((\Sigma^{-1} - \Sigma^{-1} S \Sigma^{-1}) d\Sigma)$ 。对照导数与微分的联系，有

$\frac{\partial l}{\partial \Sigma} = (\Sigma^{-1} - \Sigma^{-1} S \Sigma^{-1})^T$ ，其零点即 Σ 的最大似然估计为 $\Sigma = S$ 。

例6【多元logistic回归】： $l = -y^T \log \text{softmax}(Wx)$ ，求 $\frac{\partial l}{\partial W}$ 。其中 y 是除一个元素为1外其它元素为0的 $m \times 1$ 列向量， W 是 $m \times n$ 矩阵， x 是 $n \times 1$ 列向量， l 是标量； \log 表示自然对数，

$\text{softmax}(a) = \frac{\exp(a)}{1^T \exp(a)}$ ，其中 $\exp(a)$ 表示逐元素求指数， 1 代表全1向量。

解1：首先将softmax函数代入并写成

$l = -y^T (\log(\exp(Wx)) - 1 \log(1^T \exp(Wx))) = -y^T Wx + \log(1^T \exp(Wx))$ ，这里要注意逐元素 \log 满足等式 $\log(u/c) = \log(u) - 1 \log(c)$ ，以及 y 满足 $y^T 1 = 1$ 。求微分，使用矩阵乘法、逐元素函数等法则： $dl = -y^T dWx + \frac{1^T (\exp(Wx) \odot (dWx))}{1^T \exp(Wx)}$ 。再套上述并做交换，注意可化简

$1^T (\exp(Wx) \odot (dWx)) = \exp(Wx)^T dWx$ ，这是根据等式 $1^T (u \odot v) = u^T v$ ，故

$dl = \text{tr}\left(-y^T dWx + \frac{\exp(Wx)^T dWx}{1^T \exp(Wx)}\right) = \text{tr}(-y^T dWx + \text{softmax}(Wx)^T dWx) = \text{tr}(x(\text{softmax}(Wx) - y)^T dW)$

。对照导数与微分的联系，得到 $\frac{\partial l}{\partial W} = (\text{softmax}(W$



解2：定义 $\mathbf{a} = W\mathbf{x}$ ，则 $l = -\mathbf{y}^T \log \text{softmax}(\mathbf{a})$ ，先同上求出 $\frac{\partial l}{\partial \mathbf{a}} = \text{softmax}(\mathbf{a}) - \mathbf{y}$ ，再利用复合法则：
$$d\mathbf{l} = \text{tr} \left(\frac{\partial l}{\partial \mathbf{a}}^T d\mathbf{a} \right) = \text{tr} \left(\frac{\partial l}{\partial \mathbf{a}}^T dW\mathbf{x} \right) = \text{tr} \left(\mathbf{x} \frac{\partial l}{\partial \mathbf{a}}^T dW \right)$$
，得到 $\frac{\partial l}{\partial W} = \frac{\partial l}{\partial \mathbf{a}} \mathbf{x}^T$ 。

最后一例留给经典的神经网络。神经网络的求导术是学术史上的重要成果，还有个专门的名字叫做BP算法，我相信如今很多人在初次推导BP算法时也会颇费一番脑筋，事实上使用矩阵求导术来推导并不复杂。为简化起见，我们推导二层神经网络的BP算法。

例7【二层神经网络】： $l = -\mathbf{y}^T \log \text{softmax}(W_2 \sigma(W_1 \mathbf{x}))$ ，求 $\frac{\partial l}{\partial W_1}$ 和 $\frac{\partial l}{\partial W_2}$ 。其中 \mathbf{y} 是除一个元素为1外其它元素为0的 $m \times 1$ 列向量， W_2 是 $m \times p$ 矩阵， W_1 是 $p \times n$ 矩阵， \mathbf{x} 是 $n \times 1$ 列向量， l 是标量； \log 表示自然对数， $\text{softmax}(\mathbf{a}) = \frac{\exp(\mathbf{a})}{\mathbf{1}^T \exp(\mathbf{a})}$ 同上， σ 是逐元素sigmoid函数

$$\sigma(a) = \frac{1}{1 + \exp(-a)}。$$

解：定义 $\mathbf{a}_1 = W_1 \mathbf{x}$ ， $\mathbf{h}_1 = \sigma(\mathbf{a}_1)$ ， $\mathbf{a}_2 = W_2 \mathbf{h}_1$ ，则 $l = -\mathbf{y}^T \log \text{softmax}(\mathbf{a}_2)$ 。在前例中已求出 $\frac{\partial l}{\partial \mathbf{a}_2} = \text{softmax}(\mathbf{a}_2) - \mathbf{y}$ 。使用复合法则，

$$d\mathbf{l} = \text{tr} \left(\frac{\partial l}{\partial \mathbf{a}_2}^T d\mathbf{a}_2 \right) = \text{tr} \left(\frac{\partial l}{\partial \mathbf{a}_2}^T dW_2 \mathbf{h}_1 \right) + \underbrace{\text{tr} \left(\frac{\partial l}{\partial \mathbf{a}_2}^T W_2 d\mathbf{h}_1 \right)}_{d_2}，使用矩阵乘法交换的迹技巧从$$

第一项得到 $\frac{\partial l}{\partial W_2} = \frac{\partial l}{\partial \mathbf{a}_2} \mathbf{h}_1^T$ ，从第二项得到 $\frac{\partial l}{\partial \mathbf{h}_1} = W_2^T \frac{\partial l}{\partial \mathbf{a}_2}$ 。接下来对第二项继续使用复合法则来求 $\frac{\partial l}{\partial \mathbf{a}_1}$ ，并利用矩阵乘法和逐元素乘法交换的迹技巧：

$$d_2 = \text{tr} \left(\frac{\partial l}{\partial \mathbf{h}_1}^T d\mathbf{h}_1 \right) = \text{tr} \left(\frac{\partial l}{\partial \mathbf{h}_1}^T (\sigma'(\mathbf{a}_1) \odot d\mathbf{a}_1) \right) = \text{tr} \left(\left(\frac{\partial l}{\partial \mathbf{h}_1} \odot \sigma'(\mathbf{a}_1) \right)^T d\mathbf{a}_1 \right)，得到$$

$$\frac{\partial l}{\partial \mathbf{a}_1} = \frac{\partial l}{\partial \mathbf{h}_1} \odot \sigma'(\mathbf{a}_1)。为求 \frac{\partial l}{\partial W_1}，再用一次复合法则：$$

$$d_2 = \text{tr} \left(\frac{\partial l}{\partial \mathbf{a}_1}^T d\mathbf{a}_1 \right) = \text{tr} \left(\frac{\partial l}{\partial \mathbf{a}_1}^T dW_1 \mathbf{x} \right) = \text{tr} \left(\mathbf{x} \frac{\partial l}{\partial \mathbf{a}_1}^T dW_1 \right)，得到 \frac{\partial l}{\partial W_1} = \frac{\partial l}{\partial \mathbf{a}_1} \mathbf{x}^T。$$

推广：样本 $(\mathbf{x}_1, \mathbf{y}_1), \dots, (\mathbf{x}_N, \mathbf{y}_N)$ ， $l = -\sum_{i=1}^N \mathbf{y}_i^T \log \text{softmax}(W_2 \sigma(W_1 \mathbf{x}_i + \mathbf{b}_1) + \mathbf{b}_2)$ ，其中 \mathbf{b}_1 是 $p \times 1$ 列向量， \mathbf{b}_2 是 $m \times 1$ 列向量，其余定义同上。

解1：定义 $\mathbf{a}_{1,i} = W_1 \mathbf{x}_i + \mathbf{b}_1$ ， $\mathbf{h}_{1,i} = \sigma(\mathbf{a}_{1,i})$ ， $\mathbf{a}_{2,i} = W_2 \mathbf{h}_{1,i} + \mathbf{b}_2$ ，则

$l = -\sum_{i=1}^N \mathbf{y}_i^T \log \text{softmax}(\mathbf{a}_{2,i})$ 。先同上可求出 $\frac{\partial l}{\partial \mathbf{a}_{2,i}} = \text{softmax}(\mathbf{a}_{2,i}) - \mathbf{y}_i$ 。使用复合法则，

$$d\mathbf{l} = \text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{2,i}}^T d\mathbf{a}_{2,i} \right) = \text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{2,i}}^T dW_2 \mathbf{h}_{1,i} \right) + \underbrace{\text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{2,i}}^T W_2 d\mathbf{h}_{1,i} \right)}_{d_2} + \text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{2,i}}^T d\mathbf{b}_2 \right)$$

，从第一项得到 $\frac{\partial l}{\partial W_2} = \sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{2,i}} \mathbf{h}_{1,i}^T$ ，从第二项得到 $\frac{\partial l}{\partial \mathbf{h}_{1,i}} = W_2^T \frac{\partial l}{\partial \mathbf{a}_{2,i}}$ ，从第三项得到到

$$\frac{\partial l}{\partial \mathbf{b}_2} = \sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{2,i}}。接下来对第二项继续使用复合法则，得到 \frac{\partial l}{\partial \mathbf{a}_{1,i}} = \frac{\partial l}{\partial \mathbf{h}_{1,i}} \odot \sigma'(\mathbf{a}_{1,i})。为求$$

$$\frac{\partial l}{\partial W_1}, \frac{\partial l}{\partial \mathbf{b}_1}，再用一次复合法则：$$

$$d_2 = \text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{1,i}}^T d\mathbf{a}_{1,i} \right) = \text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{1,i}}^T dW_1 \mathbf{x}_i \right) + \text{tr} \left(\sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{1,i}}^T d\mathbf{b}_1 \right)，得到$$

$$\frac{\partial l}{\partial W_1} = \sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{1,i}} \mathbf{x}_i^T，\frac{\partial l}{\partial \mathbf{b}_1} = \sum_{i=1}^N \frac{\partial l}{\partial \mathbf{a}_{1,i}}。$$

解2：可以用矩阵来表示N个样本，以简化形式。定义 $X = [\mathbf{x}_1, \dots, \mathbf{x}_N]$ ，

$$A_1 = [\mathbf{a}_{1,1}, \dots, \mathbf{a}_{1,N}] = W_1 X + \mathbf{b}_1 \mathbf{1}^T，H_1 = [\mathbf{h}_{1,1}, \dots, \mathbf{h}_{1,N}] = \sigma(A_1)，$$

$$A_2 = [\mathbf{a}_{2,1}, \dots, \mathbf{a}_{2,N}] = W_2 H_1 + \mathbf{b}_2 \mathbf{1}^T，注意这里使用全1向量来扩展维度。先同上求出$$

$$\frac{\partial l}{\partial A_2} = [\text{softmax}(\mathbf{a}_{2,1}) - \mathbf{y}_1, \dots, \text{softmax}(\mathbf{a}_{2,N}) - \mathbf{y}_N]。使用复合法则，$$

$$d\mathbf{l} = \text{tr} \left(\frac{\partial l}{\partial A_2}^T dA_2 \right) = \text{tr} \left(\frac{\partial l}{\partial A_2}^T dW_2 H_1 \right) + \underbrace{\text{tr} \left(\frac{\partial l}{\partial A_2}^T W_2 dH_1 \right)}_{d_2} + \text{tr} \left(\frac{\partial l}{\partial A_2}^T d\mathbf{b}_2 \mathbf{1}^T \right)，从第一$$

项得到 $\frac{\partial l}{\partial W_2} = \frac{\partial l}{\partial A_2} H_1^T$ ，从第二项得到 $\frac{\partial l}{\partial H_1} = W_2^T \frac{\partial l}{\partial A_2}$ ，



来对第二项继续使用复合法则，得到 $\frac{\partial l}{\partial A_1} = \frac{\partial l}{\partial H_1} \odot \sigma'(A_1)$ 。为求 $\frac{\partial l}{\partial W_1}, \frac{\partial l}{\partial b_1}$ ，再用一次复合法则：
 $dl_2 = \text{tr} \left(\frac{\partial l}{\partial A_1}^T dA_1 \right) = \text{tr} \left(\frac{\partial l}{\partial A_1}^T dW_1 X \right) + \text{tr} \left(\frac{\partial l}{\partial A_1}^T db_1 \mathbf{1}^T \right)$ ，得到 $\frac{\partial l}{\partial W_1} = \frac{\partial l}{\partial A_1} X^T$ ，
 $\frac{\partial l}{\partial b_1} = \frac{\partial l}{\partial A_1} \mathbf{1}$ 。

下篇见zhuanlan.zhihu.com/p/24...。

编辑于 2019-05-16


机器学习 矩阵分析 优化

推荐阅读

矩阵求导术（下）

本文承接上篇
<https://zhuanlan.zhihu.com/p/24...>
来讲矩阵对矩阵的求导术。使用小写字母x表示标量，粗体小写字母 \boldsymbol{x} 表示列向量，大写字母X表示矩阵。矩阵对矩阵的求...

长躯鬼侠



深度学习线性代数简明教程

论智

发表于论智

矩阵求导的理解（

《矩阵求导术》重点：量对矩阵的求导一元（对标量）中的导数与 $df=f&\#39;(x)dx$ 多元（对向量）中的梯度与 $df=\sum_{i=1}^n \nabla$

codin...

发表

248 条评论

⇌ 切换为时间排序

写下你的评论...



精选评论（2）



resurrectcore

2 年前

网上有个pdf叫做 The Matrix Cookbook.

👍 22

🗨 查看回复



知乎用户 回复 resurrectcore

2 年前

我看过，相信写这篇文章的人也看过。感觉这里的方法比硬背公式简单，而且对于搞机器学习的这里的够用了

👍 25

🗨 查看回复

评论（248）



方不觉

2 年前

nbnb，一直对矩阵求导感觉无从下手，这几条法则比背公式好记多了！

👍 10



resurrectcore

2 年前

网上有个pdf叫做 The Matrix Cookbook.

👍 22



知乎用户 回复 resurrectcore

2 年前

我看过，相信写这篇文章的人也看过。感觉这里的方法比硬背公式简单，而且对于搞机器学习的这里的够用了

▲ 赞同 2.2K ▼

🗨 248 条评论

➦ 分享

★ 收藏

...